

Analyseprotokoll Lauf 2

Tabellarisches Q-Learning zur robotergestützten Sortierung
mit Ausnutzung der Puffersymmetrie

Niko

Diskrete Simulation und Reinforcement Learning

22. August 2026

Zusammenfassung

Dieses Protokoll dokumentiert den zweiten Trainingslauf des tabellarischen Q-Learning-Agenten für die Sortierung eingehender Teile auf zwei Puffer mit Return-Loop. Gegenüber Lauf 1 wurde ausschließlich die Maßnahme M4 (Ausnutzung der Puffersymmetrie) umgesetzt. Die Symmetrie ist bit-exakt korrekt implementiert; die Zahl der unterschiedlichen Fehlerlogiken sinkt von acht auf fünf, und alle vier explizit dokumentierten Fehlerzeilen aus Lauf 1 sind behoben. Das Explorationsdefizit (M1–M3) wurde nicht adressiert und äußert sich in Lauf 2 an neuen, teils gravierenderen Stellen. Als neuer Hauptbefund wird die weiterhin ungenutzte *Typ*-Symmetrie identifiziert.

Inhaltsverzeichnis

1	Zielsetzung und Änderungen gegenüber Lauf 1	2
2	Verifikation der Symmetrieimplementierung	2
2.1	Spiegelpaare	2
2.2	Selbstsymmetrische Zustände	2
3	Abdeckung des Zustandsraums	2
4	Qualität der gelernten Policy	3
5	Verbleibende Fehlerklassen	3
5.1	Diagnose	3
5.2	Verschärfung gegenüber Lauf 1	4
6	Neuer Hauptbefund: ungenutzte Typ-Symmetrie	4
6.1	Lösungsvorschlag: relative Kodierung	4
7	Struktur der Wertefunktion	5
8	Auffälligkeit: Absenkung des Q-Niveaus	5
9	Maßnahmen für Lauf 3	5
10	Fazit	6

1 Zielsetzung und Änderungen gegenüber Lauf 1

Ziel von Lauf 2 war die Überprüfung der Wirksamkeit von Maßnahme M4 aus dem Protokoll zu Lauf 1: die Ausnutzung der strukturellen Symmetrie der beiden Puffer. Die Spiegelung ist definiert als der gleichzeitige Tausch von

$$(b1typ, b1cat) \longleftrightarrow (b2typ, b2cat) \quad \text{und} \quad \text{Action}_0 \longleftrightarrow \text{Action}_1.$$

Tabelle 1: Umsetzungsstand der in Lauf 1 empfohlenen Maßnahmen

Nr.	Maßnahme	Zweck	Status
M1	Optimistische Q -Initialisierung	Erzwingt Erstbesuch aller Aktionen	offen
M2	ε -Minimum	Verhindert vollständigen Explorationsstopp	offen
M3	UCB / Besuchszähler	Gezielte Exploration seltener Zustände	offen
M4	Puffersymmetrie	Halbierung der zu lernenden Klassen	ok
M5	Kompaktere Zustandskodierung	Eliminiert unmögliche Zustände	offen
M6	Nächster Ankunftstyp im Zustand	Ermöglicht Lookahead	offen

Reward-Design, Diskontfaktor und Zustandsdimension blieben unverändert. Die Q -Tabelle umfasst weiterhin $432 \text{ Zustände} \times 3 \text{ Aktionen}$ (Puffer 1, Puffer 2, Return-Loop).

2 Verifikation der Symmetriemplementierung

2.1 Spiegelpaare

Für Spiegelpaare muss der Q -Wert der jeweils gewählten Aktion exakt übereinstimmen. Tabelle 2 zeigt eine repräsentative Stichprobe.

Tabelle 2: Stichprobe der Spiegelpaare, Zustand als $(inc, b1typ, b2typ, b1cat, b2cat)$

Paar	Zustand	Q gewählt	Gespiegelt	Q gewählt	Status
9 / 36	(1,0,1,1,1)	417,64688454714667	(1,1,0,1,1)	417,64688454714667	ok
54 / 81	(1,1,2,1,1)	412,9399113166976	(1,2,1,1,1)	412,9399113166976	ok
99 / 126	(1,2,3,1,1)	402,826410225901	(1,3,2,1,1)	402,826410225901	ok
359 / 413	(3,1,3,3,3)	510,6411597942206	(3,3,1,3,3)	510,6411597942206	ok

2.2 Selbstsymmetrische Zustände

Zustände mit $b1typ = b2typ$ und $b1cat = b2cat$ sind zu sich selbst symmetrisch; für sie muss $Q(s, \text{Action}_0) = Q(s, \text{Action}_1)$ gelten. Dies ist in Lauf 2 durchgängig erfüllt für die Zeilen

$$0, 45, 90, 135, 242, 279, 283, 333, 378, 386, 423.$$

In Lauf 1 wählten die Leerzustände 0, 144 und 288 noch widersprüchlich Puffer 2, Puffer 1 und Puffer 1. Diese Inkonsistenz ist behoben.

Bewertung: Maßnahme M4 ist vollständig und fehlerfrei umgesetzt. Effektiv mussten nur **111 Symmetrieklassen** statt 219 betriebsrelevanter Zustände gelernt werden; die Sample-Effizienz verdoppelt sich damit rechnerisch.

3 Abdeckung des Zustandsraums

Die 132 unmöglichen Zeilen existieren weiterhin, da Maßnahme M5 nicht umgesetzt wurde. Sie belegen unverändert 30,6% des Speichers, ohne Information zu tragen.

Tabelle 3: Aufteilung der 432 Zeilen der Q-Tabelle

Kategorie	Zustände	Anteil	Status
Strukturell unmöglich ($typ = 0 \wedge cat > 1$)	132	30,6 %	alle exakt 0,0 – korrekt
Betriebsrelevant	219	50,7 %	100 % trainiert, $Q \approx 387 \dots 511$
Beide Puffer gleicher Typ	81	18,8 %	untrainiert, alle $Q < 81$
davon nie besucht	28	6,5 %	exakt 0,0
Summe	432	100 %	

4 Qualität der gelernten Policy

Tabelle 4: Trefferquoten nach Entscheidungssituation, Lauf 2 gegen Lauf 1

Situation	Korrekte Aktion	Treffer	Quote	Lauf 1
Beide Puffer leer	symmetrisch	3 / 3	—	inkonsistent
Ein Puffer leer, anderer = <i>inc</i> (Match)	Match-Puffer	18 / 18	100,0 %	95–97 %
Ein Puffer leer, anderer Fremdtyp	leeren Puffer belegen	32 / 36	88,9 %	91,7 %
Beide belegt, ein Match	Match-Puffer	102 / 108	94,4 %	≈ 96 %
Beide belegt, kein Match (strikt)	Return	34 / 54	63,0 %	68,5 %
dito, Opfern als valide gewertet	—	54 / 54	100,0 %	9 von 11
Gesamt, strikte		189 / 219	86,3 %	88,4 %
Bewertung				
Gesamt, mit		209 / 219	95,4 %	92,6 %
Opfer-Toleranz				

Interpretation

- Der **Match-Vorrang bei leerem Gegenpuffer** ist mit 100 % vollständig gelernt.
- Das **Opfer-Kriterium** ist nun strikt konsistent: In allen 20 Opferentscheidungen wird ausnahmslos der *weniger* gefüllte Puffer überschrieben, nie der vollere. In Lauf 1 galt dies nur in 9 von 11 Fällen.
- Die **strikte Gesamtquote sinkt** leicht von 88,4 % auf 86,3 %. Dies ist ein Artefakt der Symmetrie: Fehler treten zwangsläufig paarweise auf und werden auf Zustandsebene doppelt gezählt, obwohl es sich um dieselbe Entscheidungslogik handelt. Die tolerante Quote steigt gleichzeitig von 92,6 % auf 95,4 %.

5 Verbleibende Fehlerklassen

5.1 Diagnose

In allen fünf Klassen liegt der Q -Wert der korrekten Aktion unter 4, entspricht also null bis zwei Besuchen. Der **argmax** entscheidet damit gegen praktisch uninitialisierte Werte. Vier der fünf Klassen enthalten die seltene Füllstandskategorie $cat = 3$. Die Ursache ist somit **unverändert ein Explorations- und ϵ -Decay-Problem** und *kein* Reward- oder Regelproblem.

Tabelle 5: Die fünf verbleibenden Fehlerlogiken (je zwei gespiegelte Zeilen)

Klasse	Zustand (Spiegel)	Gewählt	Q gewählt	Korrekt / Q korrekt
K1	20 / 78 (1,0,2,1, 3)	Return	445,01	P1 / 0,092
K2	298 / 327 (3,0,1,1,2)	Return	421,93	P1 / -0,035
K3	200 / 231 (2,1,2,1, 3)	P1	420,59	P2 (Match!) / 2,198
K4	206 / 233 (2,1,2, 3,3)	Return	448,08	P2 (Match!) / 2,042
K5	251 / 278 (2,2, 3,3,3)	P2	423,17	P1 (Match!) / 3,671

5.2 Verschärfung gegenüber Lauf 1

Die Fehler haben ihre Qualität verändert:

- In **Lauf 1** lagen alle acht Fehler in der ökonomisch günstigeren Kategorie „leerer Puffer versus Return“.
- In **Lauf 2** betreffen K3–K5 nun *Match-Zustände mit cat = 3*. In K5 überschreibt der Agent einen zu etwa 90 % gefüllten Fremdpufer, statt seinen eigenen nahezu vollständigen Stapel zu vollenden. Das kostet zwei Auslagerungen statt keiner.

Die alten Fehlerzeilen 29, 61, 173 und 299 aus Lauf 1 sind sämtlich korrigiert. Die Zahl der unterschiedlichen Fehlerlogiken sinkt von **8 auf 5**.

6 Neuer Hauptbefund: ungenutzte Typ-Symmetrie

Die *Puffer* sind nach M4 symmetrisch, die *Typ-Labels* jedoch nicht. Funktional identische Situationen werden weiterhin sechsfach getrennt gelernt.

Tabelle 6: Sechs funktional identische Zustände: Match bei $cat = 1$, Fremdpufer $cat = 1$

Zustand	Bedeutung	Q (Match-Aktion)
54	Match $cat = 1$, Fremd $cat = 1$	412,94
63	dito	430,95
225	dito	402,16
243	dito	404,65
405	dito	434,26
414	dito	407,67
Spannweite		402–434 ($\approx 8\%$)

Bei $cat = 3$ wird die Streuung kritisch: Die Werte lauten 494,85, 496,70, 510,64 und 440,79 – und zwei der sechs Fälle (K4, K5) sind vollständig falsch gelernt. Inhaltlich zeigt sich die Redundanz ebenso: Zustand 105 (3, 2, 3, 3, 1) opfert korrekt den $cat = 1$ -Puffer, der typgleiche Fall 348 (3, 1, 2, 3, 1) wählt hingegen Return.

6.1 Lösungsvorschlag: relative Kodierung

Eine relative Kodierung je Puffer über $\{\text{leer, match, mismatch}\} \times cat$ reduziert den Zustandsraum auf $7 \times 7 = 49$ und mit Puffersymmetrie auf **28 Klassen**. Sowohl *inc* als auch die Typ-Labels entfallen vollständig, und die Daten aller sechs Blöcke werden gepoolt. Bei etwa sechsfacher effektiver Datenmenge pro Klasse ist die Beseitigung von K3–K5 mit hoher Wahrscheinlichkeit zu erwarten.

7 Struktur der Wertefunktion

Tabelle 7: Q -Werte der gewählten Aktion, Zustände 351–359 ($inc = 3$, $b1typ = 1$, $b2typ = 3$, Match auf Puffer 2)

$b1cat \setminus b2cat$	1	2	3
1	434,26	462,30	492,39
2	452,33	472,78	496,32
3	469,14	483,14	510,64

Die Werte sind streng monoton steigend in *beiden* Füllständen und damit sauberer als in Lauf 1, wo Dubletten wie 669,2 auftraten. Die Füllstandsmerkmale werden also nachweislich informativ genutzt. In anderen Blöcken (etwa 54–62) ist die Monotonie allerdings nur bezüglich des *Zielpuffers* stabil, bezüglich des Gegenpuffers verrauscht.

Unverändert problematisch: Die nicht gewählten Aktionen liegen bei $-0,1 \dots -2$ und tragen keine Information. Es existiert weiterhin **keine verwertbare zweitbeste Aktion**, was Fallback-Strategien und Policy-Robustheitsanalysen unmöglich macht.

8 Auffälligkeit: Absenkung des Q -Niveaus

Tabelle 8: Vergleich der absoluten Q -Niveaus

	Lauf 1	Lauf 2	Verhältnis
Maximum	700,2	510,64	72,9 %
Minimum (trainiert)	509,5	386,87	75,9 %

Bei identischem Reward-Design und identischer Episodenzahl müsste die Symmetrienutzung die Werte *schneller* konvergieren lassen, nicht auf etwa 73 % absenken.

Offene Frage: Wurden Reward, γ , Episodenzahl oder Episodenlänge mitverändert? Falls nicht, deutet das Niveau auf eine *unterkonvergierte* Wertefunktion hin. In diesem Fall sind die Quoten in Tabelle 4 als untere Schranke zu lesen.

9 Maßnahmen für Lauf 3

Tabelle 9: Priorisierte Maßnahmenliste

Nr.	Maßnahme	Bezug	Priorität
M1	Optimistische Initialisierung $Q_0 \approx 520$	K1–K5	hoch
M2	$\varepsilon_{\min} = 0,05$ statt vollständigem Decay	K1–K5	hoch
M3	Besuchszählbasierte Exploration (UCB)	K3–K5	hoch
M8	Relative Typkodierung {leer, match, mismatch}	Abschnitt 6	hoch
M5	$cat = 0$ für leere Puffer	132 Leerzeilen	mittel
M7	Besuchszähler mitloggen	Auswertbarkeit	mittel
M6	Nächsten Ankunftstyp in den Zustand	Return vs. Opfer	niedrig

Maßnahme M4 ist erledigt und muss nicht erneut angefasst werden. Ohne M1–M3 wird jeder weitere Lauf dieselben drei bis acht unerforschten $cat = 3$ -Zustände falsch entscheiden – lediglich an wechselnden Stellen.

10 Fazit

1. Die Puffersymmetrie ist **bit-exakt korrekt** implementiert; alle Spiegelpaare und selbstsymmetrischen Zustände sind konsistent.
2. Die Zahl der unterschiedlichen Fehlerlogiken sinkt von **8 auf 5**; alle vier dokumentierten Fehlerzeilen aus Lauf 1 sind behoben.
3. Match-Vorrang bei leerem Gegenpuffer (100 %) und Opfer-Kriterium (100 % konsistent) sind vollständig gelernt.
4. Das **Explorationsdefizit besteht unverändert** und trifft in Lauf 2 sogar ökonomisch teurere Match-Zustände mit $cat = 3$.
5. Als neuer Hauptbefund ist die **Typ-Symmetrie** zu nennen: sechsfach redundantes Lernen identischer Situationen mit bis zu 8 % Wertestreueung. Eine relative Kodierung würde den Zustandsraum auf 28 Klassen reduzieren.
6. Das abgesenkte Q -Niveau ($\approx 73\%$ von Lauf 1) ist vor der Interpretation der Quoten zu klären.