

Analyseprotokoll

Q-Learning Lauf 1

Roboterassistierte Sortierung auf zwei Puffer

Gegenstand	Auswertung der Q-Tabelle des ersten tabellarischen Q-Learning-Trainings
Anwendungsfall	Sortierung eingehender Teile auf zwei Puffer, Fehlläufer über Return-Loop
Datenbasis	Q-Tabelle als CSV, 432 Zustände $\times$ 3 Aktionen
Zustandsraum	(inc, b1typ, b2typ, b1cat, b2cat), erzeugt über verschachtelte Schleifen (inc außen, b2cat innen)
Aktionen	A_0 = Puffer 1, A_1 = Puffer 2, A_2 = Return-Loop
Methode	Dekodierung des Zeilenindex, Soll-Ist-Vergleich der arg max-Policy gegen fachliche Regel, Monotonieprüfung der Wertefunktion
Datum	21. August 2026

Inhaltsverzeichnis

1	Ausgangslage und Zielsetzung	2
2	Abdeckung des Zustandsraums	2
3	Was der Agent gelernt hat	2
3.1	Prioritätskette der Zuweisung	2
3.2	Nichttriviales Zusatzverhalten: gelerntes Opfer-Kriterium	3
3.3	Wertefunktion nutzt die Füllstandsdiskretisierung	3
4	Was der Agent nicht gelernt hat	4
4.1	Fehlentscheidungen – alle mit identischer Ursache	4

1 Ausgangslage und Zielsetzung

Ziel des Trainings war es, ohne vorgegebene Heuristik eine Zuweisungsstrategie zu erlernen, die eingehende Teile so auf zwei Puffer verteilt, dass möglichst viele vollständige 10er-Auslagerungen entstehen und die Return-Loop möglichst selten genutzt wird.

Geprüft wurden drei Fragen:

1. Hat der Agent eine fachlich sinnvolle Strategie gelernt?
2. Nutzt er die Diskretisierung der Füllstände (`cat`) tatsächlich?
3. Welche Zustände sind unzureichend gelernt und warum?

2 Abdeckung des Zustandsraums

Tabelle 1: Aufteilung der 432 Tabellenzeilen nach Erreichbarkeit und Besuchsstatus

Kategorie	Zust.	Anteil	Besucht	Bewertung
Strukturell unmöglich (<code>typ = 0 ∧ cat > 1</code>)	132	30,6 %	0	korrekt, exakt 0,0
Betriebsrelevant (Puffer leer / ungl. Typen)	219	50,7 %	219 (100 %)	vollständig gelernt
Beide Puffer gleicher Typ	81	18,8 %	49 (60 %)	$Q < 66$, meist < 3
davon nie besucht	32	7,4 %	0	—

Feststellung. Der betriebsrelevante Teilraum ist zu 100 % erschlossen. Die Zustände „beide Puffer enthalten denselben Typ“ treten unter der gelernten Policy praktisch nicht auf – der Agent hat implizit gelernt, dass das Aufteilen eines Typs auf zwei Puffer beide Auslagerungen verzögert. Die geringe Abdeckung dieser 81 Zustände ist damit ein *Resultat der Policy*, kein *Trainingsmangel*.

3 Was der Agent gelernt hat

3.1 Prioritätskette der Zuweisung

Tabelle 2: Soll-Ist-Vergleich der $\arg \max$ -Policy über alle 216 trainierten Zustände

Situation	Korrekte Aktion	Treffer	Quote
<code>inc = b1typ</code> (Match Puffer 1)	Puffer 1	61 / 63	96,8 %
<code>inc = b2typ</code> (Match Puffer 2)	Puffer 2	60 / 63	95,2 %
ein Puffer leer, anderer Fremdtype	leeren Puffer belegen	33 / 36	91,7 %
beide belegt, kein Match	Return	37 / 54	68,5 %
beide leer	symmetrisch beliebig	3 / 3	—
Gesamt		194 / 216	88,4 %

Der Agent hat die Regel **Match** → **freier Puffer** → **Return** selbstständig und quasi-deterministisch gefunden.

3.2 Nichttriviales Zusatzverhalten: gelerntes Opfer-Kriterium

Die 17 Abweichungen in der Kategorie „beide belegt, kein Match“ sind überwiegend keine Fehler. In 9 von 11 Fällen mit ungleichem Füllstand überschreibt der Agent gezielt den Puffer mit dem *niedrigeren* cat-Wert, statt die Return-Loop zu nutzen.

Tabelle 3: Zustände mit gelerntem Opfer-Kriterium (fett: niedrigerer Füllstand)

Zeile	Zustand (inc, b1typ, b2typ, b1cat, b2cat)	Aktion	Interpretation
101	1, 2, 3, 1 , 3	Puffer 1	opfert den fast leeren Puffer
106	1, 2, 3, 3, 1	Puffer 2	opfert den fast leeren Puffer
128	1, 3, 2, 1 , 3	Puffer 1	dito
129	1, 3, 2, 2, 1	Puffer 2	dito
212	2, ..., 2 , 3	Puffer 1	dito
347	3, ..., 2 , 3	Puffer 1	dito
348	3, 1, 2, 3, 1	Puffer 2	dito
375	3, 2, 1, 3, 1	Puffer 2	dito

Der Agent wägt also **Rückführkosten gegen Sortierfortschritt** ab – ein Verhalten, das eine handgeschriebene „Match-first / sonst Return“-Heuristik nicht enthält. Werden diese 9 Fälle als sinnvoll gewertet, steigt die Policy-Qualität auf **92,6 %**.

3.3 Wertefunktion nutzt die Füllstandsdiskretisierung

Tabelle 4: Q-Wert der gewählten Aktion für inc = 1, b1typ = 2, b2typ = 1 (Match auf Puffer 2, Zeilen 81–89)

b1cat	b2cat		
	1	2	3
1	605,3	625,4	659,6
2	625,8	645,0	669,2
3	641,7	669,2	690,1

Die Werte steigen monoton in *beiden* Füllständen. Daraus folgt:

- Der Füllstand des Zielpuffers wird korrekt als Nähe zur 10er-Auslagerung bewertet.
- Auch der Füllstand des *anderen* Puffers erhöht den Zustandswert $\Rightarrow$ der Agent besitzt einen Fortschrittsbegriff für den Gesamtzustand, nicht nur eine lokale Regel.
- **Nachweis, dass die cat-Features informativ genutzt werden** und kein toter Ballast im Zustandsvektor sind.

Wertespanne der trainierten Zustände: 509,5 (Zeile 180) bis 700,2 (Zeile 125). Return-Q-Werte liegen mit 511–687 im gleichen Band; die Schleife wird als moderat teuer, nicht als katastrophal bewertet.

4 Was der Agent nicht gelernt hat

4.1 Fehlentscheidungen – alle mit identischer Ursache

Tabelle 5: Alle 8 Fehlentscheidungen der gelernten Policy

Zeile	Zustand (inc, b1typ, b2typ, b1cat, b2cat)	Gewählt	Q gewählt	Q korrekt
29	1, 0, 3, 1, 3	Return	606,3	P1 = 0,00
173	2, 0, 3, 1, 3	Return	612,1	P1 = 0,26
299	3, 0, 1, 1, 3	Return	627,3	P1 = 0,05
245	2, 2, 3, 1, 3	Return	624,7	P1 = 0,73
61	1, 1, 2, 3 , 2	Puffer 2	544,0	P1 = 2,14
353	3, 1, 3, 1, 3	Puffer 1	611,0	P2 = 9,59
356	3, 1, 3, 2, 3	Puffer 1	607,7	P2 = 2,05
359	3, 1, 3, 3, 3	Puffer 1	598,1	P2 = 13,50